

Лабораторная работа №2 — Линейная классификация

Предсказание уровня
предупреждения землетрясений
(alert)

Никита Крушинин, 307

Постановка задачи

- Датасет о землетрясениях за период 2001–2023 гг. (Kaggle, Earthquake Dataset).
- Цель: по характеристикам события предсказать уровень предупреждения $\text{alert} \in \{\text{green}, \text{yellow}, \text{orange}, \text{red}\}$.
- Тип задачи: многоклассовая классификация.
- Практический смысл: приоритизация потенциально опасных землетрясений для служб мониторинга и оповещения.

Описание датасета

- Всего объектов: 782 записи о землетрясениях.
- Числовые признаки: magnitude, cdi, mmi, tsunami, sig, nst, dmin, gap, depth, latitude, longitude.
- Категориальные признаки: net, magType, continent, country, location, а также дата-время события.
- Целевая переменная: alert — уровень предупреждения (4 класса по цветам).

Подготовка и очистка данных


- Проверка типов признаков и пропусков (`df.info()`, `df.isnull().sum()`).
- Обработка пропусков в географических признаках `continent` и `country` с помощью `RadiusNeighborsClassifier` по координатам.
- Строки без целевой переменной `alert` исключены из обучения.
- Обработка выбросов в глубине и сигналах (`depth`, `sig`, `nst`, `gap`, `dmin`): анализ квантилей и ограничение экстремальных значений.
- Масштабирование числовых признаков для линейных моделей (`StandardScaler`).

Распределение целевой переменной alert


- Классы сильно несбалансированы: доминирует уровень «green» (наименее опасные события).
- «Yellow» и «orange» представлены существенно меньшим числом наблюдений.
- «Red» встречается редко — наиболее опасные землетрясения.
- Такой дисбаланс требует оценки F1-score и ROC-AUC, а не только Accuracy, и аккуратной настройки регуляризации.

Распределения числовых признаков

Распределения числовых признаков



Корреляционная матрица числовых признаков



Выводы по EDA

- Магнитуда (magnitude) лежит в диапазоне 6.5–9.1: в выборке только довольно сильные землетрясения.
- Показатели интенсивности cdi и mmi умеренно коррелируют с магнитудой и значимостью события sig .
- Часть геометрических признаков ($dmin$, gap) имеет сильно скошенные распределения и единичные большие выбросы.
- Около 39 % событий сопровождались цунами ($tsunami = 1$).

Выбор модели

- Рассматривались базовые модели: SVM, Logistic Regression, KNN, Decision Tree, Random Forest, Gradient Boosting, XGBoost, CatBoost.
- Для демонстрации в презентации выбрана модель Logistic Regression (сквозная линейная модель).
- Причины выбора: интерпретируемость коэффициентов, скорость обучения, устойчивость к переобучению при правильной регуляризации.
- Дополнительно реализован собственный класс логистической регрессии для более глубокого понимания метода.

Конфигурация Logistic Regression (sklearn)

- Библиотека: scikit-learn, класс LogisticRegression.
- Многоклассовый режим: `multi_class = "multinomial"` с `solver = "lbfgs"`.
- Регуляризация: L2 (параметр C подбирался по сетке; итоговое значение ≈ 1.0).
- Обучение с кросс-валидацией `StratifiedKFold(n_splits = 5, shuffle = True, random_state = 42)`.
- Входные признаки: стандартизированные числовые + ONE-кодированные категориальные.

Качество Logistic Regression (5-fold CV)

- Accuracy ≈ 0.896 — модель правильно классифицирует $\sim 90\%$ примеров.
- F1-score (macro) ≈ 0.73 — хорошее среднее качество по всем классам с учётом дисбаланса.
- ROC-AUC (macro) ≈ 0.97 — отличное разделение классов по вероятностным оценкам.
- Модель показывает лучший баланс интерпретируемости и качества среди протестированных алгоритмов.

Собственный класс логистической регрессии

- Реализована с нуля на NumPy: softmax-регрессия с кросс-энтропийным loss-функционалом.
- Оптимизация: градиентный спуск с L2-регуляризацией и обучением по мини-батчам.
- Поддержка многоклассовой классификации (one-vs-rest через softmax).
- Реализованы методы `fit`, `predict`, `predict_proba` для совместимости с остальным кодом лабораторной работы.

Качество собственной логистической регрессии

- Первая версия модели: Accuracy ≈ 0.81 , F1-score ≈ 0.24 , ROC-AUC ≈ 0.95 — заметная недонастройка и проблемы с балансом классов.
- После настройки шагов обучения и регуляризации: Accuracy ≈ 0.86 , F1-score ≈ 0.66 , ROC-AUC ≈ 0.95 .
- Сравнение со sklearn-подходом показало, как сильно качество зависит от корректной реализации оптимизации.
- Итог: собственная реализация близка по ROC-AUC, но немного уступает по F1-score и стабильности.

Интерпретация модели и бизнес-эффект

- Наиболее важные признаки: magnitude, sig, mmi — характеризуют силу землетрясения и субъективную интенсивность.
- Признаки tsunami, depth и геометрия измерений (gap, dmin) дают дополнительную информацию о потенциальной опасности.
- Модель позволяет автоматически ранжировать новые события по уровням alert и фокусировать внимание на более опасных случаях.
- Решение легко интегрируется в существующий пайплайн мониторинга землетрясений и масштабируется на новые данные.

Выводы и дальнейшая работа

- Построен полный ML-пайплайн: EDA, предобработка, обучение нескольких моделей и выбор лучшей.
- Logistic Regression показала высокое качество (F1 и ROC-AUC) при хорошей интерпретируемости.
- Собственный класс логистической регрессии подтвердил понимание теории и позволил экспериментировать с оптимизацией.
- В дальнейшем можно дообучать CatBoost/XGBoost, добавить балансировку классов и оптимизировать метрику F1 для редких классов.