

Лабораторная работа 3: подбор гиперпараметров для детекции фрода

Никита Крушинин, группа 307

Цели и метрики

- Повысить качество детекции редких мошеннических транзакций.
- Ключ: PR-AUC (Average Precision).
Дополнительно: ROC-AUC.
- Accuracy — только справочно из-за сильного дисбаланса.
- Порог классификации подбирается отдельно (например, по F2).

Данные и особенности

- Признаки $V1...V28$ — PCA-компоненты; дополнительные: Time и Amount.
- Class сильно разряжён: положительных примеров кратно меньше.
- Все преобразования выполняются внутри CV-пайплайна, чтобы исключить утечку.

Препроцессинг

- Скейлинг Time и Amount (Robust/StandardScaler) внутри ColumnTransformer.
- Опционально: Time_sin/Time_cos для учета суточной периодики.
- Балансировка классов через class_weight='balanced'.


Стратегия валидации

- Stratified K-Fold ($k=5$).
- Отдельный тестовый набор до подбора гиперпараметров.
- Оптимизация по PR-AUC, контроль ROC-AUC.

Модели и поиск гиперпараметров

- RandomForestClassifier в пайплайне со скейлингом.
- Grid Search, Random Search, Optuna (TPE); ТРОТ для авто-пайплайнов.
- class_weight='balanced', подбор регуляризаторов и глубины.

Диаграмма: PR-AUC по методам



Выводы и следующие шаги

- Grid/Random Search нашли одинаково сильный пайплайн (PR-AUC $\approx$ 0.847).
- Optuna дала более консервативные настройки: PR-AUC ниже, Accuracy выше из-за дисбаланса.
- Подбирать рабочий порог по PR-кривой (например, F2).
- Дальше: попробовать бустинг (HistGB/XGBoost), time-based split, cost-sensitive подход (Amount), калибровку вероятностей.